

学习笔记

WangYe

2026 年 6 月 6 日

生成模型 · 强化学习后训练 · arXiv 论文雷达 · 论文精读 · Survey · 系统与推理 · 面试
复盘

目录

视频音频方向：Bidirectional Causal Audio-Visual Editing 调研与 Roadmap	3
1 一句话定位	3
2 为什么这个 idea 值得做	3
2.1 当前方法的缺口	3
2.2 核心研究问题	4
3 相关工作地图	5
3.1 直接相关工作	5
3.2 关键基础能力	5
4 任务定义：从“编辑对象”升级为“编辑因果 AV source layer”	6
4.1 输入输出	6
4.2 编辑类型	7
4.3 因果传播规则	7
5 推荐系统设计	7
5.1 模块化 pipeline baseline	8
5.2 Module A: Source Grounding	8
5.3 Module B: Causal Edit Planner	9
5.4 Module C: Video Editor	9
5.5 Module D: Audio Editor	10
5.6 Module E: AV Consistency Refiner	10
6 数据路线	11
6.1 最小可行数据集	11
6.2 建议优先场景	11
7 实验设计与评价指标	12
7.1 Baseline 组合	12
7.2 指标	12
7.3 关键 ablation	13
8 Roadmap	13
8.1 阶段 0：两周内复现和搭 baseline	13
8.2 阶段 1：1-2 个月内做出可投稿 workshop 的方法雏形	14

8.3 阶段 2: 3-6 个月内形成主论文贡献	14
8.4 阶段 3: 6-12 个月内冲击顶会主线	15
9 我建议的论文卖点	15
10 风险与应对	16
11 下一步具体执行清单	16
12 资料来源	17

视频音频方向：Bidirectional Causal Audio-Visual Editing 调研与 Roadmap

1 一句话定位

目标：给定源视频帧 V 、源音频 A 、用户编辑指令 I ，以及可选的视觉 mask、音频时间段、对象点击或参考声音，生成编辑后的视频 $\hat{V}$ 和音频 $\hat{A}$ 。系统不仅要完成用户指定的视觉或声音编辑，还要把同一个**因果音视频源层**中的可见对象、声音 stem、动作事件、空间位置、阴影/反射/遮挡/混响等副作用一起更新，同时尽量保留无关区域和无关声源。

我建议把老师给的 idea 命名为：**Bidirectional Causal Audio-Visual Source Editing**。它不是单纯的 video editing，也不是单纯的 Foley/audio generation，而是把一个对象及其声音看作一个可插拔、可删除、可替换的**causal audio-visual source layer**：

$$S_i = \{M_i(t), B_i(t), z_i^{vis}, z_i^{aud}, E_i, p_i(t), r_i(t), C_i\},$$

其中 $M_i(t)$ 是对象 mask/track, $B_i(t)$ 是 bounding box/trajectory, z_i^{vis} 是视觉身份, z_i^{aud} 是声学身份, E_i 是事件时间线, $p_i(t)$ 是空间位置, $r_i(t)$ 是房间/环境响应, C_i 是与其他对象、背景和声音的因果关系。编辑操作本质上是在这些 source layer 上做 insertion、removal、replacement、attribute change 或 temporal change。

2 为什么这个 idea 值得做

2.1 当前方法的缺口

现有工作大致分成四类，但每类都只覆盖了问题的一部分：

1. **视频对象编辑/移除：**例如 EffectErase [3] 能做高质量视频对象和视觉 effect erasing，强调去除对象带来的形变、阴影、反射等视觉副作用。但它默认是无声视频侧的编辑，不能处理对象消失后对应声音也应消失的问题。

2. **联合音视频生成:** JavisDiT [2] 证明了 joint audio-video generation 可以从开放文本提示生成同步的声音和视频, 并显式强调空间同步、时间同步和时空同步。但它主要是从零基础生成, 不是对已有视频做局部可控编辑。
3. **对象级音视频编辑:** Object-AVEdit [1] 已经非常接近, 它做 object-level audio-visual addition、replacement、removal, 并提出 word-to-sounding-object aligned audio generation 与 inversion-regeneration 编辑流程。但这个方向仍有空间: 它更像“对象级语义编辑”, 而老师的 idea 可以进一步推进到**源层因果一致性**, 即显式建模 visible object、sound stem、motion event、spatial audio、visual side effects 和原场景保真之间的统一约束。
4. **音视频源定位/分离:** The Sound of Pixels [6]、Looking to Listen [7]、Audio-Visual Segmentation [8]、AudioSep [9] 等能把“声音来自哪里”和“如何分离目标声音”做出来, 但它们通常不是完整的编辑系统, 也不直接生成编辑后的视频和音频。

因此, 一个明确的研究 gap 是: **现有方法缺少面向真实视频的、双向触发的、参考条件控制的、以因果音视频源层为单位的编辑系统。**

2.2 核心研究问题

Research Question: 当用户编辑一个可见对象或一个可听声源时, 系统如何判断另一模态是否需要被更新, 并在需要时只更新同一个因果源层, 同时保留无关视觉区域、无关音频 stem 和原始场景语义?

这个问题可以拆成五个子问题:

1. **Source grounding:** 用户点击一只狗、圈出一个人、选择一段 barking 音频或输入“dog barking”, 系统如何确定这是同一个 source?
2. **Source separation:** 如何把目标声音 stem 从混合音频中分离出来, 同时保留环境声和其他对象声音?
3. **Causal edit propagation:** 如果删掉狗, 狗叫声、脚步声、阴影、遮挡、反射、环境混响是否也要删? 如果只是给狗换颜色, 声音是否不应改变?
4. **Reference-conditioned generation:** 如果插入一个 reference character 或 reference sound, 如何同时保持视觉身份、声学身份、动作事件同步和空间位置一致?
5. **Preservation and evaluation:** 如何衡量目标编辑成功、非目标内容保留、音视频同步、空间音频一致和声学自然度?

3 相关工作地图

3.1 直接相关工作

工作	解决了什么	对本 idea 的启发
Object-AVEdit [1]	object-level audio-visual addition / replacement / removal; 使用 inversion-regeneration paradigm, 并训练 word-to-sounding-object aligned audio generation model。	最直接 baseline。我们的差异点应放在: 显式 source-layer 表示、双向因果传播、参考声学身份、空间音频与原场景保留。
JavisDiT [2]	joint audio-video diffusion transformer; 从文本同时生成视频和声音, 提出 hierarchical spatio-temporal synchronized prior。	可作为音视频同步生成 backbone 或 teacher; 但它偏生成而非局部编辑。
JUST-DUB-IT [4]	用 joint audio-visual diffusion + LoRA 做视频配音, 同时生成翻译音频和同步脸部运动。	证明“修改音频触发视觉运动变化”是可行的; 但它聚焦 speech/lip dubbing, 不覆盖一般对象声源。
EffectErase [3]	视频对象移除与插入互逆学习; 强调 object effect erasing, 如阴影、反射、形变。	是视觉侧 removal/insertion 强 baseline; 可以接音频分离/补全模块变成 AV baseline。

3.2 关键基础能力

能力	代表工作/工具	在本项目中的角色
视觉对象定位与交互 mask	Grounding DINO [11]、SAM [12]、SAM 2 [13]	文本/点击/框选对象; SAM 2 负责视频 mask propagation。

发声对象像素定位	Audio-Visual Segmentation / AVSBench [8]	从音频引导视觉 segmentation, 回答“当前声音来自哪个可见对象”。
视觉引导音频分离	The Sound of Pixels / PixelPlayer [6]、Looking to Listen [7]	把 mask/face/object visual embedding 用作目标声源分离条件。
文本查询音频分离	AudioSep [9]	第一版最实用的 target sound separation baseline: 输入“dog barking”、“violin”等文本 prompt。
通用音频 stem 分离	Demucs [10]	可作为工程 baseline, 尤其是音乐/人声/鼓点等 stem 结构明确的场景。
对象视觉移除/插入	EffectErase [3]、video inpainting / video diffusion editing	负责 $V \rightarrow \hat{V}$, 尤其处理遮挡、阴影、反射、背景修复。
音频补全/生成	JavisDiT [2]、Qwen-TTS / Foley / audio diffusion models	负责 $A \rightarrow \hat{A}$, 生成新增对象声音、填补删除后的环境声、维持时空同步。

4 任务定义：从“编辑对象”升级为“编辑因果 AV source layer”

4.1 输入输出

给定：

$$(V, A, I, U),$$

$$U \in \{\text{mask, click, bbox, audio span, text prompt, reference image, reference sound}\}.$$

输出：

$$(\hat{V}, \hat{A}, \hat{G}, \hat{R}),$$

其中 $\hat{G}$ 是目标 source 的 grounding 结果，例如 mask track、audio stem、事件边界； $\hat{R}$ 是可解释的 edit propagation report，例如“删除狗：删除狗 mask、狗叫 stem、狗脚步声、狗阴影，保留背景鸟叫和人声”。

4.2 编辑类型

1. **Visual-to-audio removal:** 用户圈出一只正在叫的狗，系统移除狗的视频对象，同时删除对应 barking/footstep stem，并保留背景环境声。
2. **Audio-to-visual removal:** 用户选择一段刺耳的鸣笛声，系统定位产生该声音的车辆；如果车辆是目标事件的一部分，则可选择移除/静音该声源，并在视频中保留车辆或删除车辆，取决于指令。
3. **Insertion:** 用户插入一只 reference dog；系统生成视觉上身份一致的狗、合理动作、对应叫声/脚步声，并把声源位置放在画面中狗的位置附近。
4. **Replacement:** 用户把画面中的 violin 换成 guitar；系统不仅改物体外观，还要把 violin sound 替换为 guitar sound，并让拨弦/扫弦事件与手部动作对齐。
5. **Attribute edit:** 用户只改颜色/衣服/位置。如果该属性不改变发声机制，音频应保持；如果改动作速度，音频事件节奏应同步变化。

4.3 因果传播规则

可以把编辑分成三类传播强度：


传播类型	触发条件	系统动作
No propagation	只改变不影响发声机制的视觉属性，例如衣服颜色、背景风格。	只改 V ，尽量保持 A 不变。
Weak propagation	改变位置、尺度、朝向、速度，但对象和声学身份不变。	更新 spatial audio、音量/混响/节奏；保留声学身份。
Strong propagation	插入/删除/替换发声对象或事件。	同步更新对象 mask、声音 stem、事件时间线、视觉/音频副作用。

这个 propagation classifier 可以先做成 rule-based + LLM parser，后续再训练成一个 edit planner。

5 推荐系统设计

5.1 模块化 pipeline baseline

第一阶段不要直接训练 end-to-end 大模型，而应该先搭一个可跑通的 modular baseline。建议结构如下：



5.2 Module A: Source Grounding

这是最关键的模块，因为老师材料里提到“怎么标出 video object 和语音是关键”。建议分三种入口：

1. **视觉入口**：用户 click/mask/bbox/text。用 Grounding DINO 找对象框，用 SAM 2 传播 mask track，得到 $M_i(t)$ 。
2. **音频入口**：用户选择 audio span 或输入 sound prompt。用 AudioSep 分离 target stem $a_i(t)$ ，再用 AVS/PixelPlayer 类模型把声音映射到画面区域。
3. **双向校验**：计算 visual event timeline 与 audio onset timeline 的一致性。如果对象运动峰值、嘴型/碰撞/敲击事件和声音 onset 对不上，说明 grounding 可能错了。

第一版可以实现如下简化：

1. 对视频每秒采样关键帧，用 Grounding DINO + SAM 2 得到 mask track。
2. 对音频跑 AudioSep 或 Demucs，得到 candidate stems。
3. 提取视觉 motion energy：

$$m_i(t) = \sum_{(x,y) \in M_i(t)} \|V_t(x, y) - V_{t-1}(x, y)\|.$$

4. 提取音频 onset energy:

$$o_j(t) = \text{OnsetDetect}(a_j(t)).$$

5. 用 cross-correlation 或 contrastive score 匹配 M_i 与 a_j :

$$\text{score}(i, j) = \max_{\tau \in [-\Delta, \Delta]} \text{corr}(m_i(t), o_j(t + \tau)).$$

这个简单 baseline 不一定 SOTA，但非常适合快速做 demo，并能把“对象和声音绑定”这个核心问题显式化。

5.3 Module B: Causal Edit Planner

Planner 的输入是 instruction + source grounding，输出是 edit graph:

$$\mathcal{P} = \{\Delta V_{target}, \Delta A_{target}, \Delta V_{side}, \Delta A_{side}, \text{preserve constraints}\}.$$

建议先做成规则系统:

指令	视觉动作	音频动作
remove dog	删除狗 + 修复背景 + 删除阴影/遮挡	删除 dog barking/footsteps; 补环境底噪。
mute dog barking	保留狗视觉; 不改动作	删除 barking stem; 保留其他声音。
replace violin with guitar	替换物体和动作细节	替换为 guitar stem; onset 对齐手部动作。
add speaking person	插入人物 + lip/motion	TTS/voice cloning 生成 speech; 同步嘴型和空间位置。
move car to left	改轨迹/位置	调整声像、音量 and 多普勒/混响, 不改变 engine identity。

后续可以训练一个 VLM/LLM planner，用人工合成的 instruction-edit graph 数据做监督。

5.4 Module C: Video Editor

视频侧建议分三档:

1. **Removal baseline:** EffectErase 或 video inpainting, 输入 target mask track, 输出 background-restored video。
2. **Insertion baseline:** reference-conditioned video diffusion / subject-driven video generation。3DreamBooth [5] 可作为视觉身份一致性的相关思路, 但它偏 3D-aware subject-driven generation, 不直接解决声音。
3. **Replacement baseline:** 先 remove, 再 inpaint/insert 新对象; 或者使用 inversion-based video editing 保留原结构。

视觉 editor 必须输出 side-effect mask, 例如被删除对象造成的阴影、反射、遮挡区域。EffectErase 的 VOR dataset 和 reciprocal insertion-removal consistency 对这点很有启发 [3]。

5.5 Module D: Audio Editor

音频侧建议分为四个操作:

1. **Separate:** 用 AudioSep 根据文本 prompt 分离 target stem; 如果是 speech, 可结合 face-guided separation, 例如 Looking to Listen。
2. **Remove:** 不要直接 waveform subtraction。建议用 target stem 估计 mask 后在 spectrogram 上做 soft subtraction, 再用 audio inpainting/denoising 补回环境纹理。
3. **Generate:** 插入对象时, 用 Foley/audio diffusion/TTS 生成新声音。老师提到 Qwen-TTS 跑起来不错, 因此 speech 类 demo 可优先用 Qwen-TTS 做语音生成, 再接 lip-sync/face editing。
4. **Spatialize:** 根据对象 screen position 和 camera motion 估计声像、距离、混响。第一版可以用简单 stereo panning:

$$g_L(t) = \sqrt{\frac{1 - x(t)}{2}}, \quad g_R(t) = \sqrt{\frac{1 + x(t)}{2}},$$

其中 $x(t) \in [-1, 1]$ 是对象在画面中的水平位置。

5.6 Module E: AV Consistency Refiner

Refiner 的目标是让最终 $\hat{V}$ 和 $\hat{A}$ 在四个层面一致:

1. **Semantic consistency:** 画面里有狗叫, 音频里也应有 dog barking; 没有狗时不应残留明显狗叫。
2. **Temporal consistency:** 嘴型、敲击、碰撞、脚步、乐器演奏等 visible event 与 audio onset 对齐。

3. **Spatial consistency**: 声音声像/响度/混响与对象位置、距离、环境相符。
4. **Preservation consistency**: 非目标对象、背景纹理、其他说话人/乐器/环境声尽量不变。

第一版 refiner 可以不训练大模型，而是做检测与反馈：如果同步评分低，则重新调整 audio onset；如果非目标区域 LPIPS/SSIM 变化大，则降低 video edit strength；如果非目标 stem 变化大，则回滚音频 mask。

6 数据路线

6.1 最小可行数据集

为了先做出 demo，不建议一开始就收大规模真实标注。可以构造一个三层数据集：

1. **Synthetic compositing set**: 从透明背景对象视频、Foley 声音库、环境底噪中合成。优点是天然知道 source mask、stem、事件时间线和干净背景。
2. **Paired removal set**: 借鉴 EffectErase 的 VOR 思路，构造 object-present / object-absent video pair；再加入 present / absent audio pair。
3. **Real-world weakly labeled set**: 从 AudioSet/VGGSound/AVSBench 类型数据中抽取带声源类别的视频，只做弱标签和少量人工标注。

6.2 建议优先场景

场景	优点	难点	适合 demo
狗叫/动物叫声	直观，声音类别清晰，适合老师提到的例子。	同画面多只狗时 source association 难。	删除某只狗及其叫声；只静音某只狗。
说话人	工具成熟：face detection、TTS、lip-sync、speaker separation。	身份、口型和语音内容评估严格。	换台词、删除某人语音、配音。

乐器演奏	motion-onset 对 齐 明 显; Pix- elPlayer/Sound of Pixels 有基础。	多乐器混音分离难, violin to guitar re- placement。 视觉动作复杂。
车辆/鸣笛/引擎	空间音频直观, 移 动轨迹明显。	车辆声音和背景交 通声高度混合。 移动车辆后声音声像 跟随。

我建议第一个 demo 选**狗叫 removal / mute**, 第二个 demo 选**说话人 dubbing**, 第三个 demo 选**乐器 replacement**。这样能覆盖非语音、语音、音乐三类主流声源。

7 实验设计与评价指标

7.1 Baseline 组合

1. **Video-only baseline:** EffectErase / video inpainting, 只改视频不改音频。
2. **Audio-only baseline:** AudioSep / Demucs, 只改音频不改视频。
3. **Naive pipeline:** video edit + audio separation/subtraction, 二者无反馈。
4. **Object-AVEdit baseline:** 直接对比 object-level AV editing。
5. **Ours modular:** source grounding + causal planner + video editor + audio editor + AV refiner。
6. **Ours learned:** 在 modular pipeline 产生的 pseudo labels 上训练端到端或半端到端模型。

7.2 指标

维度	可用指标	意义
目标视觉编辑	mask-region LPIPS/FID/FVD、CLIP text-image alignment、human preference	目标对象是否正确删除、插入 或替换。

非目标视觉保留	outside-mask PSNR/SSIM/LPIPS、tracking consistency	不相关区域是否被破坏。
目标音频编辑	SDR/SI-SDR、CLAP alignment、AudioLDM/AudioSet classifier score	目标声音是否删除/生成/替换成功。
非目标音频保留	background SDR、speaker similarity、stem leakage score	其他声源是否被误伤。
时间同步	onset-motion correlation、SyncNet/AV sync score、event boundary error	声音事件是否与画面动作同步。
空间一致性	audio panning error、visual position-stereo correlation、human spatial preference	声音位置是否跟随可见对象。
整体质量	MOS、pairwise human preference、artifact rating	人类是否认为自然可信。

7.3 关键 ablation

1. 去掉 source grounding，只用文本 prompt 做音频编辑。
2. 去掉 causal planner，所有视觉编辑都强制改音频。
3. 去掉 AV refiner，观察 motion-onset 同步下降。
4. 用 AudioSep vs 视觉引导分离 vs 二者融合。
5. 用硬 subtraction vs spectrogram soft mask vs audio inpainting。

8 Roadmap

8.1 阶段 0：两周内复现和搭 baseline

目标：跑通一个最小系统：用户点击/框选视频里的目标对象，系统删除该对象并删除对应声音，输出一个可展示的 demo。

1. 整理 20–50 个短视频样例，优先选择单声源或双声源，时长 3–8 秒。

2. 接入 SAM 2 做对象 mask track；如果是文本对象，则用 Grounding DINO + SAM 2。
3. 接入 AudioSep，用文本 prompt 分离目标声音，例如 “dog barking”。
4. 视频侧先用现成 video inpainting / EffectErase 类模型；音频侧先做 soft mask removal。
5. 写一个简单 UI 或脚本：输入视频、点击对象、输入 sound prompt，输出 $\hat{V}, \hat{A}$ 。

交付物：一个 dog barking removal demo；一页 failure cases；一个 baseline 指标表。

8.2 阶段 1：1–2 个月内做出可投稿 workshop 的方法雏形

1. 实现 visual-to-audio 和 audio-to-visual 双向 grounding：
 - visual click/mask $\rightarrow$ target stem；
 - audio span/prompt $\rightarrow$ sounding object mask。
2. 引入 motion onset 和 audio onset 的 source association score，显式解决“哪只狗在叫”。
3. 做 causal edit planner，至少覆盖 remove、mute、replace、insert 四类操作。
4. 收集/合成 500–2000 个 paired examples，包含 object mask、stem、event timestamp。
5. 与 video-only、audio-only、naive pipeline、Object-AVEdit 做系统对比。

交付物：完整 modular pipeline；初版 benchmark；ablation；demo page。

8.3 阶段 2：3–6 个月内形成主论文贡献

1. 训练一个 **Causal AV Source Adapter**：把视觉 mask track、audio stem、event timeline 编码成统一 source token。
2. 在 joint diffusion/video diffusion/audio diffusion backbone 上加 source-conditioned editing branch。
3. 设计 preservation loss：outside-mask visual preservation、non-target stem preservation、source identity preservation。
4. 设计 AV causal consistency loss：

$$\mathcal{L}_{av} = \mathcal{L}_{sem} + \lambda_t \mathcal{L}_{time} + \lambda_s \mathcal{L}_{spatial} + \lambda_p \mathcal{L}_{preserve}.$$

5. 构造更难的多源场景：两只狗、一人说话一人弹琴、车流鸣笛、多人对话。

交付物：方法论文核心；强对比；用户研究；真实复杂场景 demo。

8.4 阶段 3：6–12 个月内冲击顶会主线

1. 构建公开 benchmark: *Causal-AVEdit-Bench*, 覆盖 insertion、removal、replacement、mute 和 spatial move。
2. 发布 source-layer annotation schema: mask track、audio stem、event boundary、source id、side-effect region。
3. 训练统一模型，支持 reference image + reference sound + instruction 的 multi-condition editing。
4. 引入人类偏好优化或 reward model，优化真实感、同步性和保真度。
5. 将 demo 扩展到交互式编辑器：点击对象、试听 stem、选择传播范围、预览编辑报告。

交付物：

- benchmark、model、project page 与 interactive demo；
- 目标投稿：CVPR、ICCV、ECCV、NeurIPS 或 ICLR 的多模态生成方向。

9 我建议的论文卖点

1. **新任务定义：**Bidirectional Causal Audio-Visual Source Editing，把对象编辑和声音编辑统一到 source layer 上。
2. **新表示：**Causal AV source layer，包含 visible object、sound stem、motion-event timeline、spatial audio 和 visual/audio side effects。
3. **新 pipeline：**source grounding → causal planner → modality-specific editors → AV consistency refiner。
4. **新 benchmark：**多源真实视频上的 insertion/removal/replacement/mute/spatial move，评价目标编辑、非目标保留、时间同步和空间一致性。
5. **强 demo：**删掉一只狗及其叫声、只静音某只狗、给无声 object removal 视频补合理声音、替换乐器并同步声音。

10 风险与应对

风险	表现	应对
目标 stem 分离不干净	删除狗叫后有残留或背景被误删。	使用 AudioSep + visual-guided separation 融合; 引入 audio inpainting 补背景。
多只同类对象 association 错误	用户选左边狗, 系统删了右边狗的声音。	motion-onset correlation + AVS segmentation + 人工点击确认。
视频编辑 artifact 明显	背景修复闪烁、阴影没删干净。	使用 EffectErase 类 effect-aware removal; 加入 temporal consistency filter。
生成声音不贴合动作	狗嘴没张却有叫声, 敲击声音延迟。	event timeline 显式控制音频 onset; 后处理 time-stretch/shift。
与 Object-AVEdit 区分不够	审稿人认为只是 pipeline 组合。	强调 bidirectional grounding、causal propagation、source-layer annotation、preservation metrics 和多源复杂场景。

11 下一步具体执行清单

1. **先复现 baseline:** Object-AVEdit、EffectErase、AudioSep、SAM 2, 确认哪些模型能本地跑。
2. **做第一个 demo:** 狗叫视频中选中一只狗, 删除视觉对象并删除对应 barking stem。
3. **补第二个 demo:** 老师提到的 EffectErase 无声结果, 尝试用 JarvisDiT/Foley/audio diffusion 或更轻量的 sound generation 给删除/插入事件配音。

4. **实现 source association:** mask motion energy 与 audio onset energy 匹配, 先不用训练。
5. **构造小 benchmark:** 每类 30–50 个样例, 覆盖 dog/person/instrument/car。
6. **写 proposal:** 用 “Object-AVEdit 的下一步: 从 object-level AV editing 到 causal AV source-layer editing” 作为叙事。

12 资料来源

参考文献

- [1] Youquan Fu, Ruiyang Si, Hongfa Wang, Dongzhan Zhou, Jiacheng Sun, Ping Luo, Di Hu, Hongyuan Zhang, and Xuelong Li. *Object-AVEdit: An Object-level Audio-Visual Editing Model*. OpenReview, ICLR 2026 submission. <https://openreview.net/forum?id=NCmgCSJTLm>
- [2] Kai Liu, Wei Li, Lai Chen, Shengqiong Wu, Yanhao Zheng, Jiayi Ji, Fan Zhou, Rongxin Jiang, Jiebo Luo, Ziwei Liu, Hao Fei, and Tat-Seng Chua. *JavisDiT: Joint Audio-Video Diffusion Transformer with Hierarchical Spatio-Temporal Prior Synchronization*. Project page, accepted by ICLR 2026. <https://javisverse.github.io/JavisDiT-page/>
- [3] Yang Fu, Yike Zheng, Ziyun Dai, and Henghui Ding. *EffectErase: Joint Video Object Removal and Insertion for High-Quality Effect Erasing*. arXiv:2603.19224, 2026. <https://arxiv.org/abs/2603.19224>
- [4] Anthony Chen, Naomi Ken Korem, Gal Zeevi, Tavi Halperin, Matan Ben Yosef, Urska Jelercic, Ofir Bibi, Or Patashnik, and Daniel Cohen-Or. *JUST-DUB-IT: Video Dubbing via Joint Audio-Visual Diffusion*. arXiv:2601.22143, 2026. <https://arxiv.org/abs/2601.22143>
- [5] Hyun-kyu Ko, Jihyeon Park, Younhyun Kim, Dongheok Park, and Eunbyung Park. *3DreamBooth: High-Fidelity 3D Subject-Driven Video Generation Model*. arXiv:2603.18524, 2026. <https://arxiv.org/abs/2603.18524>

-
- [6] Hang Zhao, Chuang Gan, Andrew Rouditchenko, Carl Vondrick, Josh McDermott, and Antonio Torralba. *The Sound of Pixels*. arXiv:1804.03160, 2018. <https://arxiv.org/abs/1804.03160>
 - [7] Ariel Ephrat, Inbar Mosseri, Oran Lang, Tali Dekel, Kevin Wilson, Avinatan Hassidim, William T. Freeman, and Michael Rubinstein. *Looking to Listen at the Cocktail Party: A Speaker-Independent Audio-Visual Model for Speech Separation*. arXiv:1804.03619, 2018. <https://arxiv.org/abs/1804.03619>
 - [8] Jinxing Zhou, Dan Guo, and Meng Wang. *Audio-Visual Segmentation*. arXiv:2207.05042, 2022. <https://arxiv.org/abs/2207.05042>
 - [9] Xuenan Xu, Zeyu Xie, Mengyue Wu, and Kai Yu. *Separate Anything You Describe*. arXiv:2308.05037, 2023. <https://arxiv.org/abs/2308.05037>
 - [10] Alexandre Defossez, Nicolas Usunier, Léon Bottou, and Francis Bach. *Music Source Separation in the Waveform Domain*. arXiv:1911.13254, 2019. <https://arxiv.org/abs/1911.13254>
 - [11] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. *Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection*. arXiv:2303.05499, 2023. <https://arxiv.org/abs/2303.05499>
 - [12] Alexander Kirillov et al. *Segment Anything*. arXiv:2304.02643, 2023. <https://arxiv.org/abs/2304.02643>
 - [13] Nikhila Ravi et al. *SAM 2: Segment Anything in Images and Videos*. arXiv:2408.00714, 2024. <https://arxiv.org/abs/2408.00714>